
基于 2.5D Residual U-Net 的 T1 MRI 去噪

课程期末作业：T1 MRI 去噪 (T1_noisy $\rightarrow$ T1_clean)

PyTorch 可复现训练、评估与断点续传 Pipeline

Abstract

本实验实现 T1 MRI 从加噪图像到干净图像的监督式去噪。数据集包含 600 个病例，体积尺寸不固定，并包含 Gaussian 与 Rician 混合噪声。为避免信息泄漏，病例划分固定为 480/60/60，脑掩膜和归一化参数仅由 noisy 图像估计，clean 图像只作为训练标签和评估真值。主方法采用 2.5D Residual 2D U-Net，以相邻 axial 切片作为 3 通道输入，并预测噪声残差而非直接预测 clean 图像。在 60 个测试病例上，该方法达到 PSNR 43.01 ± 1.82 dB、SSIM 0.9959 ± 0.0015 ，相对 noisy 输入提升 1.25 dB PSNR，并在所有测试病例上优于 Gaussian smoothing 与 NLM 基线。

1 数据与预处理

本实验选择 T1 MRI 去噪任务。每个病例包含 T1_noisy.nii.gz 与 T1_clean.nii.gz。实测体积尺寸范围约为 $156\text{--}208 \times 203\text{--}256 \times 166\text{--}256$ ，因此代码不假设固定尺寸。所有图像为 RAS 朝向、1 mm 各向同性体素，axial 切片沿第 3 轴。

数据按病例而非切片划分，固定随机种子为 42，得到 480 个训练病例、60 个验证病例和 60 个测试病例，并写入 split.json。所有脚本读取同一划分文件，以避免切片级泄漏。

预处理只使用 noisy 图像估计脑掩膜和归一化参数。脑掩膜由 Gaussian 平滑、Otsu 阈值、形态学清理和最大连通域筛选得到。归一化使用 noisy 脑区第 1 和第 99.5 百分位作为 (lo, hi) ，并对 noisy 与 clean 共用：

$$\hat{x} = \frac{x - lo}{hi - lo}, \quad \hat{y} = \frac{y - lo}{hi - lo}. \quad (1)$$

这保证 clean 图像不参与输入侧统计量估计。预处理结果缓存为 .npz，训练时仅采样脑区占比超过 1% 的 axial 切片。

2 方法

训练样本由中心 axial 切片及其前后相邻切片组成：

$$X_k = [x_{k-1}, x_k, x_{k+1}] \in \mathbb{R}^{3 \times H \times W}. \quad (2)$$

标签为 clean 的中心切片 y_k 。训练阶段随机裁剪 192×192 patch，并使用水平和垂直翻转增强。验证和测试阶段对整张切片推理，先 padding 到 16 的倍数，再裁回原尺寸。

模型为 Residual 2D U-Net，输入通道数为 3，输出通道数为 1，base channel 为 48，共 4 层下采样。每个 stage 使用残差卷积块，上采样采用双线性插值。网络预测噪声残差 $r_\theta(X_k)$ ，最终输出为

$$\hat{y}_k = x_k - r_\theta(X_k). \quad (3)$$

该设计将学习目标集中在 noisy 与 clean 的差异上，更符合去噪任务。

损失函数为

$$\mathcal{L} = \|\hat{y} - y\|_1 + 0.2(1 - \text{SSIM}(\hat{y}, y)) + 0.1\mathcal{L}_{grad}. \quad (4)$$

其中 SSIM 的 data_range 固定为 1.0，梯度损失使用 Sobel 梯度图的 L1 距离，用于降低过平滑。

3 训练设置与断点续传

训练使用 AdamW，学习率 10^{-4} ，weight decay 10^{-4} ，batch size 16，最大 60 epoch，并启用 AMP 混合精度。每个 epoch 后在 60 个验证病例上做整卷推理，以脑掩膜内 PSNR 选择最优模型。

断点续传保存两类 checkpoint: `last.pt` 与 `best.pt`。`last.pt` 包含模型、优化器、scheduler、AMP scaler、epoch、global step、best PSNR、early stopping 计数、随机状态和配置；`best.pt` 在验证 PSNR 刷新时保存。保存过程先写临时文件，再用 `os.replace` 原子替换目标文件。训练脚本启动时默认从 `last.pt` 续训，只有显式指定 `--resume none` 才从头训练。为减少 I/O 开销，最终配置不按 step 保存，而是每 2 epoch 保存一次中间状态，同时保留 best checkpoint。

最终训练到 epoch 60。最佳验证结果也出现在 epoch 60，验证 PSNR 为 43.0978 dB，验证 SSIM 为 0.9960。训练曲线如图 1 所示。




图 1: 训练损失、验证 PSNR、验证 SSIM 与学习率曲线。

4 结果

评估在 60 个测试病例上进行。所有指标只在 noisy 推导出的脑掩膜内统计，预测结果先 clip 到 $[0, 1]$ ，并固定 `data_range=1.0`。比较方法包括 Noisy、Gaussian smoothing、NLM 和 Residual U-Net。

表 1: 测试集整体结果 (mean $\pm$ std)。MAE/RMSE 越低越好，PSNR/SSIM 越高越好。

Method	MAE $\downarrow$	RMSE $\downarrow$	PSNR $\uparrow$	SSIM $\uparrow$
Gaussian	0.0091 ± 0.0009	0.0125 ± 0.0010	38.09 ± 0.66	0.9932 ± 0.0019
NLM	0.0066 ± 0.0015	0.0084 ± 0.0019	41.77 ± 2.05	0.9937 ± 0.0026
Noisy	0.0067 ± 0.0016	0.0084 ± 0.0020	41.76 ± 2.15	0.9936 ± 0.0029
Residual U-Net	0.0057 ± 0.0011	0.0072 ± 0.0014	43.01 ± 1.82	0.9959 ± 0.0015

Residual U-Net 在全部指标上优于三种基线。PSNR 相比 Noisy 提升 1.2508 dB，相比 NLM 提升 1.2412 dB，相比 Gaussian smoothing 提升 4.9238 dB。图 2 给出了指标对比。




图 2: 不同方法的测试集指标对比。

按 `rician_sigma` 将测试病例分为低、中、高噪声三档，每档 20 例。Residual U-Net 在三档中均获得最高 PSNR。相对 Noisy 的 PSNR 增益从低噪声的 0.98 dB 增至高噪声的 1.52 dB，说明该模型在更强混合噪声下收益更明显。

表 2: 按 Rician 噪声强度分层的 PSNR (dB, mean $\pm$ std)。

Method	Low noise	Mid noise	High noise
Gaussian	38.53 ± 0.61	38.17 ± 0.43	37.57 ± 0.56
NLM	43.31 ± 1.95	41.82 ± 1.40	40.19 ± 1.48
Noisy	43.41 ± 2.05	41.80 ± 1.44	40.09 ± 1.52
Residual U-Net	44.39 ± 1.77	43.04 ± 1.20	41.61 ± 1.27




图 3: Residual U-Net 相比 Noisy 的 PSNR 增益随噪声强度增加而增大。

配对检验进一步支持该提升。Residual U-Net 在 60/60 个测试病例上 PSNR 均高于 Noisy、Gaussian 和 NLM。与 Noisy 相比，PSNR 平均差为 +1.2508 dB，配对 t 检验 $p = 4.17 \times 10^{-35}$ ，Wilcoxon 符号秩检验 $p = 1.63 \times 10^{-11}$ 。与 NLM 相比，PSNR 平均差为 +1.2412 dB，配对 t 检验 $p = 2.06 \times 10^{-40}$ 。

5 定性分析

图 4 展示了测试病例 1000542 的 axial 中层切片。Residual U-Net 降低了 noisy 图像中的随机纹理噪声，同时保留脑室、皮层和深部结构边界。残余误差主要集中在组织边界附近。




图 4: 测试病例 1000542 的 axial 视图: noisy、Residual U-Net 输出、clean 与绝对误差图。

图 5 给出了同一病例的 sagittal/coronal/axial 多平面视图。虽然模型按 axial 方向进行 2.5D 推理，重建体在其他平面上未见明显切片级断裂。




图 5: 测试病例 1000542 的多平面可视化。

6 为何不继续训练

本实验不再继续延长当前配置的训练。主要原因是模型已经到达 60 epoch，最佳验证结果出现在最后一个 epoch，但最后若干 epoch 的提升幅度很小。训练后期学习率已接近 0，验证 PSNR 从 epoch 53 的 43.0953 dB 到 epoch 60 的 43.0978 dB，仅提升约 0.0025 dB。这说明当前配置已基本进入平台期。

继续使用相同数据、相同模型和相同学习率计划训练，预期收益很低，并可能增加过拟合风险。若要进一步提升，优先方向应是新的实验设计，例如 3D 网络、模型集成、测试时增强或关键模块消融，而不是简单增加 epoch。

7 结论

本项目完成了可复现、可断点续传的 T1 MRI 去噪 pipeline。主方法在测试集上达到 PSNR 43.01 ± 1.82 dB、SSIM 0.9959 ± 0.0015 ，并在所有测试病例上优于 Noisy、Gaussian smoothing 和 NLM。结果表明，2.5D 残差学习能在当前 Gaussian + Rician 混合噪声设置下稳定降低误差。当前实验的主要边界是：模型并非完整 3D 网络，结果基于单一病例级划分，且尚未在外部 MRI 数据上验证。